

## **Aplicación de algoritmos de Deep Clustering en procesamiento de imágenes**

La clasificación y segmentación no supervisada de conjuntos de datos complejos, como imágenes y registros de clientes, es uno de los problemas en el mundo actual donde se producen inmensas cantidades de datos no estructurados, lo que se convierte en uno de los objetivos centrales del aprendizaje automático moderno. La idea de estos nuevos algoritmos es partir de un conjunto de imágenes, registros de clientes o datos no etiquetados previamente, y descubrir automáticamente, a partir de una serie de algoritmos internos de aprendizaje estadístico, estructuras latentes en los datos que permitan agruparlos de acuerdo con su contenido semántico. Esta capacidad tiene aplicaciones directas en la organización masiva de archivos multimedia, análisis de imágenes médicas sin anotación experta, y detección de patrones visuales en dominios donde el etiquetado manual es costoso o inviable.

En este contexto, los métodos de Deep Clustering han surgido como una respuesta a las limitaciones de los métodos clásicos de agrupamiento frente a datos de alta dimensionalidad, mostrando ventajas al integrar aprendizaje de representaciones profundas compactas, asignación de clústeres y generación de estructuras latentes más discriminativas, sin supervisión explícita.

### **Objetivo**

Descubrir agrupaciones semánticamente coherentes de imágenes no etiquetadas, en el entrenamiento de algoritmos de Deep Clustering. Con esto, se busca comparar el desempeño de varios modelos de Deep Clustering a la hora de producir representaciones latentes más separables y agrupaciones más consistentes.

en conjuntos de datos de diferente naturaleza y de grandes tamaños en un marco de análisis más profundo y exhaustivo que incluyen modelos de clustering clásico que se optimizan de forma iterativa internamente.

### **Metodología**

De manera general, el proceso de Deep Clustering comienza con una etapa inicial de extracción y aprendizaje de características mediante una red neuronal profunda (frecuentemente autoencoders o modelos basados en aprendizaje contrastivo). Estas redes aprenden a mapear los datos originales hacia espacios latentes de menor dimensionalidad que preservan información esencial sobre la estructura inherente de los datos originales. Posteriormente, en este espacio latente se realizan procesos de agrupamiento empleando métodos clásicos. Así, la calidad final del clustering depende críticamente de la eficacia con la que la red neuronal captura la estructura subyacente de los datos en las representaciones latentes.

Para los conjuntos de datos se propone utilizar métodos DEC y IDEC de Deep Clustering basados en autoencoders profundos (AE), métodos basados en autoencoders variacionales (VAE) como VaDE, y métodos basados en aprendizaje contrastivo como SimCLR o SPICE.

## Datasets

- **STL-10:** Contiene 10 clases de imágenes a color de  $96 \times 96$ , con 500 imágenes de entrenamiento por clase y 800 de prueba por clase, para un total de 13,000 imágenes etiquetadas; además incluye 100,000 imágenes no etiquetadas provenientes de una distribución similar pero más amplia, pensadas para aprendizaje no supervisado (Xie, 2016).
- **BloodMNIST:** Imágenes microscópicas de células sanguíneas periféricas normales tomadas de individuos sin infección, sin enfermedad hematológica u oncológica y sin tratamiento farmacológico al momento de la toma. está compuesto por 17,092 imágenes RGB de células sanguíneas periféricas, organizadas en 8 clases y divididas en 11,959 muestras de entrenamiento, 1,712 de validación y 3,421 de prueba. Se propone este dataset como secundario.

## Métricas de desempeño

Dado que el proyecto se plantea en un marco no supervisado, la validación se realizará por medio de métricas internas de clustering, que solo valoran la calidad de los grupos a partir de la estructura de los datos y de las representaciones latentes aprendidas, nuevamente sin recurrir a etiquetados. Entre éstas, están:

- **Silhouette Score:** Mide simultáneamente cohesión intra-clúster y separación entre clústeres. Se mide entre -1 y 1, y un valor más alto indica grupos más compactos y mejor separados (Aranyi & Böröczky, 2024).
- **Índice Calinski-Harabasz (CHI):** Evalúa la razón entre la dispersión de clústeres y dispersión dentro de los clústeres. Un valor alto sugiere una mejor partición (Caliński & Harabasz, 1974).
- **Índice Davies-Bouldin (DBI):** Determina la similitud promedio entre cada clúster y su clúster más cercano. Valores más bajos indican mejor desempeño (Davies & Bouldin, 1979).
- **Inercia intra-clúster o Within-Cluster Sum of Squares (WCSS):** Cuantifica qué tan compactos son los clústeres obtenidos, especialmente en métodos basados en centroides (Hartigan & Wong, 1979).
- **Tiempo de entrenamiento y costo computacional:** Se medirá el tiempo requerido por cada modelo y, si es posible, el consumo de memoria o de GPU, con el fin de contrastar calidad del clustering frente a viabilidad práctica.

## Resultados

DEC demostró que el Deep Clustering puede superar enfoques clásicos (Xie, 2016), y posteriormente IDEC se propuso como una mejora de DEC al incorporar una pérdida de reconstrucción para preservar la estructura local del espacio latente y evitar que la optimización del clustering degrade la representación, mostrando mejoras consistentes frente a DEC en sus experimentos.

Un patrón consistente en la literatura es que los métodos más recientes basados en aprendizaje contrastivo superan sistemáticamente a los enfoques basados en autoencoders.

## Referencias

- [1] Xie, J., Girshick, R., & Farhadi, A. (2016). Unsupervised deep embedding for clustering analysis. ICML 2016.
- [2] Min, E., Guo, X., Liu, Q., Zhang, G., Cui, J., & Long, J. (2018/2023). A Survey on Deep Clustering. Vicinagearth / Springer Nature, 2024.
- [3] Yang, B., Fu, X., Sidiropoulos, N. D., & Hong, M. (2017). Towards K-Means-Friendly Spaces: Simultaneous Deep Learning and Clustering. In ICML 2017.
- [4] Guo, X., Liu, X., Zhu, E., & Yin, J. (2017). Deep Clustering with Convolutional Autoencoders. ICONIP 2017.
- [5] Li, Y., Hu, P., Liu, Z., Peng, D., Zhou, J. T., & Peng, X. (2021). Contrastive Clustering. AAAI 2021.
- [6] Aranyi, G., & Böröczky, K. J. (2024). Deep Clustering Using the Soft Silhouette Score: Towards Compact and Well-Separated Clusters. arXiv:2402.00608.
- [7] Hartigan, J. A., & Wong, M. A. (1979). A K-means clustering algorithm. Journal of the Royal Statistical Society: Series C (Applied Statistics), 28(1), 100–108. <https://doi.org/10.2307/2346830>